Exercício Entrevista: Data Science & Machine Learning

Contexto de Negócio

Você acabou de ingressar no time de Data Science & Machine Learning — Anti-Fraud & Risk. A empresa processa transações de e-commerce e pagamentos online.
O objetivo central do time é equilibrar a aprovação de vendas legítimas e o bloqueio de fraudes. Em termos de negócio:

- Falsos Negativos (Fraude Aprovada): Resultam em prejuízo financeiro direto (chargeback, perda do valor da transação e custos operacionais).
- Falsos Positivos (Venda Legítima Rejeitada): Resultam em atrito com o cliente, redução no LTV/fidelidade e perda da margem de lucro (ROI) da transação.

Atualmente, a empresa busca substituir/complementar as regras heurísticas manuais por um modelo preditivo de Machine Learning robusto e interpretável, capaz de atuar em tempo real.

Estrutura dos Dados (nuvem_fraud_dataset.csv)

O arquivo fornecido contém dados históricos de transações com features cadastrais, geográficas, contextuais e o rótulo final de fraude (is_fraud).

Coluna	Descrição	Exemplo / Formato
created_at	Data e hora em que a transação ocorreu (UTC)	2019-01-01 00:00:44+00:00
store_name	Nome do estabelecimento/loja	'Heller, Gutmann and Zieme'
vertical	Categoria de negócio do e-commerce	grocery_pos, shopping_net, misc_net
amount	Valor financeiro da transação	107,23 (String com vírgula)

Coluna	Descrição	Exemplo / Formato
device	Dispositivo de origem do pagamento	Mobile, Web
card_brand	Bandeira do cartão de crédito/débito	Master Card, Visa, Amex
city / state	Cidade e Estado do comprador	Orient, WA
lat / long	Latitude e Longitude do comprador	48|8878, -118|2105
city_population	População estimada da cidade	149
job	Ocupação do comprador	'Special educational needs teacher'
date_of_birth	Data de nascimento do comprador	1978-06-21 00:00:00+00:00
store_lat / store_long	Coordenadas da loja	49|159047, -118|186462
is_fraud	Target: 1 se foi fraude (chargeback), 0 se legítima	0 ou 1

Desafio do Candidato (Instruções do Case)

Sua tarefa é aplicar os passos fundamentais do ciclo de vida de Data Science & ML, desde o tratamento dos dados até a definição de uma estratégia de decisão baseada no valor financeiro/ROI para o negócio.

Seu entregável será um Jupyter Notebook (ou código equivalente modularizado - utilize o *Google Colab/Databricks* se julgar necessário) documentado e uma apresentação executiva (PDF/Slides) sintetizando a solução técnica e o impacto no negócio.

Parte 1: Ciclo de Machine Learning (Mão na Massa)

1. Análise Exploratória & Limpeza dos Dados (EDA):
    - Realize o parse correto dos tipos de dados (tratar delimitadores ;, números decimais com vírgula ,, coordenadas com |, datas) e identifique valores nulos ou inconsistentes.
    - Analise o desbalanceamento da variável target (is_fraud) e o comportamento do valor financeiro (amount) em relação à fraude.
2. Engenharia de Features (Feature Engineering):
    - Crie features temporais (ex: hora do dia, dia da semana, idade do cliente com base na date_of_birth).
    - Crie features geográficas/comportamentais (ex: distância entre o comprador e a loja usando lat/long e store_lat/store_long).
    - Aplique técnicas adequadas de codificação para variáveis categóricas de alta cardinalidade (vertical, card_brand, etc.).
3. Treinamento e Validação do Modelo:
    - Divida os dados em treino e teste garantindo a preservação da linha temporal (evitando data leakage das transações).
    - Experimente e compare ao menos dois algoritmos (ex: Logistic Regression, Random Forest, XGBoost/LightGBM).
    - Avalie o desempenho técnico utilizando métricas adequadas para dados desbalanceados (ex: PR-AUC, ROC-AUC, Precision, Recall, F1–Score).

Parte 2: Decisão de Negócio — Risco de Fraude vs. Maximização do ROI

Em ambiente de produção, um modelo de risco não fornece apenas 0 ou 1, mas uma probabilidade de fraude. A decisão de corte (Threshold Decision) define o equilíbrio entre receita mantida e custo de fraude.
Considere a seguinte estrutura simplificada de P&L (Lucro e Perda):

- Falso Negativo (FN - Fraude Não Detectada): A transação é aprovada, mas era fraude. *Custo = 100% do amount + Taxa Operacional de Chargeback (ex: R$ 15,00).*
- Falso Positivo (FP - Cliente Legítimo Rejeitado): A transação legítima é bloqueada. *Custo = Margem Financeira Perdida (ex: 10% do amount) + Custo Operacional de Análise Manual.*
- Verdadeiro Positivo (TP - Fraude Bloqueada): Fraude evitada com sucesso.

- Verdadeiro Negativo (TN - Venda Legítima Aprovada): Receita gerada com sucesso.

Você deve responder e apresentar:

1. Otimização de Threshold: Como você definiu o ponto de corte (Threshold) de probabilidade para aprovar, recusar ou enviar a transação para revisão manual?
2. Simulação Financeira (Curva de ROI): Apresente uma comparação do impacto financeiro do uso do seu modelo em relação a um cenário baseline (aprovar tudo ou regra heurística simples).
3. Métricas de Negócio: Mostre o resultado esperado no Índice de Chargeback Financeiro (%) e na Taxa de Aprovação de Vendas (%).

Parte 3: Arquitetura & MLOps em Produção (Visão ponta-a-ponta)

Explique brevemente na sua apresentação/documentação como abordaria a operacionalização do modelo:

1. Deploy & Serving: Como a predição seria servida no momento do checkout (ex: API em tempo real com baixa latência)?
2. Feature Store: Como garantir a consistência das features entre treino e inferência em tempo real?
3. Monitoramento & Governança de ML: Como monitorar Data Drift, Concept Drift (mudança nos padrões de fraude) e a degradação de performance do modelo ao longo do tempo?
4. Se o fluxo for batch (predições em lotes): Como seguiria?